

Data yang diambil dari website IMDb (Internet Movie Database, https://www.imdb.com) yang disusun berdasarkan popularitas film di tahun 2017 dengan user rating antara 5 dan 10 dan hanya diambil 100 film teratas. Data tersebut dapat diakses melalui link berikut: https://www.imdb.com/search/title/?title_type=feature&release_date=2017-01-01,2017-12-31&user_rating=5.0,10.0&count=100

Langkah-langkah Web Scraping dengan R:

- 1. Install dan panggil package "xm12' dan "rvest" dengan perintah dalam R seperti berikut :
 - > install.packages("xml2")
 - > library(xml2)
 - > install.packages("rvest")
 - > library(rvest)

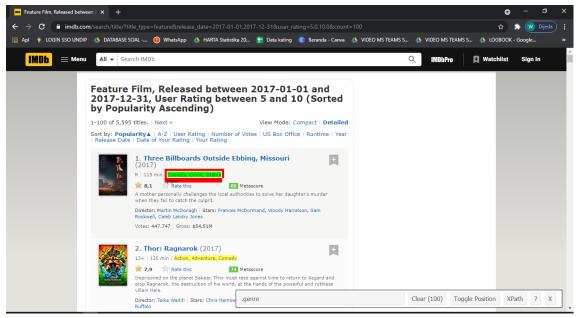
Kemudian akan diperoleh hasil running sebagai berikut

2. Kemudian lihat alamat dari website dan masukkan ke dalam R dengan perintah seperti berikut:

```
> alamat_website <-
"https://www.imdb.com/search/title/?title_type=feature&rele
ase_date=2017-01-01,2017-12-
31&user_rating=5.0,10.0&count=100"
> website <-read_html(alamat_website)
> website
```

Kemudian akan diperoleh hasil running sebagai berikut

3. Mengambil data genre yang ada pada halaman website dengan bantuan SelectorGadget



kemudian masukkan perintah ke dalam R seperti berikut :

```
> genre_data_website <-html_nodes(website, ".genre")
> genre_data_website
> data_genre <-html_text(genre_data_website)
> data_genre
> data_genre <-gsub("\n","",data_genre)
> data_genre
> data_genre <-gsub(" ","",data_genre)
> data_genre
> data_genre
> data_genre
> data_genre
> data_genre <-gsub(",.*","",data_genre)
> data_genre
> data_genre <-gsub(",.*","",data_genre)
> data_genre
```

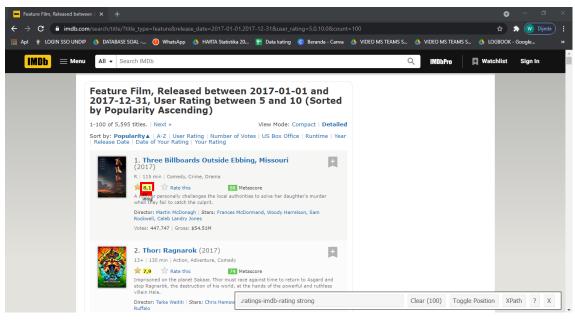
Maka akan diperoleh hasil running sebagai berikut

> data genre

```
| Console | Terminal | Jobs |
```

```
rama
ction, Fantasy, Thriller
```

4. Selanjutnya mengambil data rating yang ada pada halaman website dengan bantuan SelectorGadget

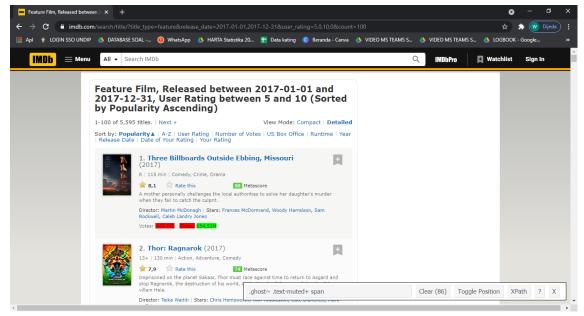


kemudian masukkan perintah ke dalam R seperti berikut :

- > rating_data_website <-html_nodes(website, ".ratings-imdbrating strong")
- > rating data website
- > data rating <-html text(rating data website)</pre>
- > data rating
- > data rating<- as.numeric(data rating)</pre>
- > data rating

Dan akan diperoleh hasil running sebagai berikut

5. Berikutnya mengambil data gross pendapatan pada halaman website dengan bantuan SelectorGadget

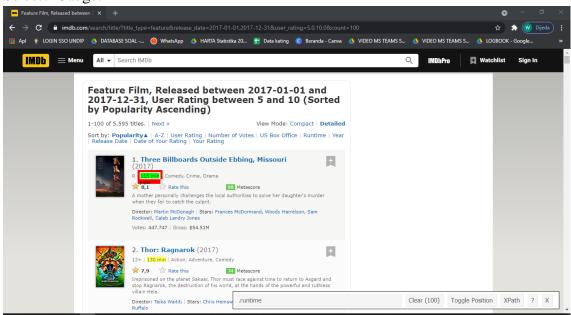


kemudian masukkan perintah ke dalam R seperti berikut :

Ternyata hanya 86 film yang memiliki nilai gross pendapatan. Sehingga nilai-nilai yang tidak ada tersebut diganti dengan "NA" dengan menggunakan perintah:

```
> gross_data_website<- html_nodes(website, ".ghost~ .text-muted+ span")
> gross_data_website
{xml_nodeset (86)}
[I] <span name="nv" data-value="34,513,740">$54.51M</span>
[2] <span name="nv" data-value="315,058,289">$315.06M</span>
[3] <span name="nv" data-value="176,040,665">$176.04M</span>
[4] <span name="nv" data-value="92,054,159">$92.05M</span>
[5] <span name="nv" data-value="92,054,159">$92.05M</span>
[6] <span name="nv" data-value="63,859,435">$68.86M</span>
[7] <span name="nv" data-value="63,859,435">$68.86M</span>
[8] <span name="nv" data-value="63,859,435">$68.86M</span>
[9] <span name="nv" data-value="168,052,812">$186.05M</span>
[10] <span name="nv" data-value="168,052,812">$186.05M</span>
[11] <span name="nv" data-value="174,340,174">$174.34M</span>
[12] <span name="nv" data-value="334,201,140">$133.420M</span>
[13] <span name="nv" data-value="18,095,701">$18.10M</span>
[14] <span name="nv" data-value="18,095,701">$18.10M</span>
[15] <span name="nv" data-value="18,095,701">$18.10M</span>
[16] <span name="nv" data-value="18,095,701">$18.10M</span>
[16] <span name="nv" data-value="127,481,748">$132.48M</span>
[17] <span name="nv" data-value="127,481,748">$132.48M</span>
[18] <span name="nv" data-value="117,445,148">$132.48M</span>
[19] <span name="nv" data-value="117,445,148">$132.48M</span>
[19] <span name="nv" data-value="117,445,148">$132.48M</span>
[19] <span name="nv" data-value="17,445,148">$132.748">$132.748M</span>
[19] <span name="nv" data-value="17,445,148">$132.748">$132.748">$132.748">$132.748">$132.748">$132.748">$132.748">$132.748">$132.748">$132.748">$132.748">$132.748">$132.748">$132.748">$132.748">$132.748">$132.748">$132.748">$132.748">$132.748">$132.748">$132.748">$132.748">$132.748">$132.748">$132.748">$132.748">$132.748">$132.748">$132.748">$132.748">$132.748">$132.748">$132.748">$132.748">$132.748">$132.748">$132.748">$132.748">$132.748">$132.748">$132.748">$132.748">$132.748">$132.748">$132.748">$132.748">$132.748">$132.748">$132.748">$132.748">$132.748">$132.748">$132.748">$13
          | 20| | | cspan name="nv" data-value="39,175,066">$39.18M
| cspan name="nv" data-value="34,26M" "$176.04M" "$92.05M" "$229.02M" "$63.86M" "$2.42M" "$404.52M" "$174.54M" "$246.01M" "$181.10M" "$107.83M" "$327.48M" "$226.01M" "$188.37M" "$40.44M" "$180.01M" "$188.37M" "$40.44M" "$182.09M" "$12.56M" "$132.42M" "$504.01M" "$41.19M" "$26.28M" "$33.70M" "$100.23M" "$40.04M" "$133.80M" "$75.47M" "$2.48M" "$146.88M" "$48.96M" "$148.96M" "$148.96M" "$148.96M" "$108.28M" "$18.04M" "$180.17M" "$2.03M" "$2.34M" "$2.34M" "$2.02M" "$22.78M" "$17.80M" "$27.78M" "$17.80M" "$27.78M" "$10.17M" "$2.03M" "$80.10M" "$40.56M" "$18.34M" "$102.09M" "$5.09M" "$21.12M" "$3.48M" "$16.79M" "$54.28M" "$34.39M" "$50.70M" "$55.68M" "$13.02M" "$54.89M" "$50.70M" "$55.70M" "$55.70M" "$51.34M" "$42.87M" "$18.30M" "$18.25M" "$18.29M" "$18.29M" "$54.89M" "$542.87M" "$34.89M" "$542.87M" "$34.89M" "$55.70M" "$55.70M" "$55.70M" "$55.70M" "$55.70M" "$56.8M" "$108.25M" "$108.25M" "$12.29M" "$51.34M" "$42.87M" "$42.87M" "$42.87M" "$42.87M" "$42.87M" "$42.87M" "$44.80M" "$66.67M" "$10.58M" "$108.25M" "$108.25M" "$12.29M" "$51.34M" "$42.87M" "$42.87M" "$42.87M" "$42.87M" "$44.80M" "$66.67M" "$10.58M" "$108.25M" "$108.2
[[1]]
[1] "54.51"
      [[2]]
[1] "315.0"
      [[3]]
[1] "176.0"
      [[4]]
[1] "92.05"
      [[5]]
[1] "229.0"
      [[6]]
[1] "63.86"
      [[7]]
[1] "2.42"
      [[8]]
[1] "404.5"
        [[9]]
[1] "168.0"
```

6. Yang terakhir mengambil data runtime dari halaman website dengan bantuan SelectorGadget



lalu masukkan perintah ke dalam R seperti berikut :

```
> runtime_data_website <-html_nodes(website, ".runtime")</pre>
```

- > runtime data website
- > data runtime <-html text(runtime data website)</pre>
- > data runtime
- > data runtime <-gsub(" min","",data runtime)</pre>
- > data runtime
- > data_runtime <-as.numeric(data runtime)</pre>
- > data runtime

Sehingga diperoleh hasil running sebagai berikut

> Statistik Deskriptif

1. Gabungkan semua data menjadi data frame dengan perintah R seperti berikut :

Kemudian akan diperoleh hasil running sebagai berikut

2. Untuk mencari statistik deskriptifnya dapat menggunakan perintah seperti berikut :

```
> summary(data_film)
#Untuk data runtime
> var(data_runtime)
> sd(data_runtime)
> modus_runtime <-function(data_runtime) {
  unik_runtime <-unique(data_runtime)
  tabel_runtime <-table(data_runtime)</pre>
```

```
sort(unik runtime)[tabel runtime == max(tabel runtime)]
> modus runtime(data runtime)
#Untuk data rating
> var(data rating)
> sd(data rating)
> modus rating <-function(data rating) {</pre>
  unik rating <-unique(data rating)</pre>
  tabel rating <-table(data rating)</pre>
  sort(unik_rating) [tabel_rating == max(tabel_rating)]
> modus rating(data rating)
#Untuk data gross pendapatan
> var(data gross)
> sd(data gross)
> modus gross <-function(data gross) {</pre>
  unik gross <-unique(data gross)</pre>
  tabel gross <-table(data gross)</pre>
  sort(unik gross)[tabel gross == max(tabel gross)]
> modus gross(data gross)
Kemudian akan diperoleh hasil running sebagai berikut
     //363
_runtime <-function(data_runtime){
k_runtime <-unique(data_runtime)
e]_runtime <-table(data_runtime)
t(unik_runtime)[tabe]_runtime == max(tabe]_runtime)]
   odus_runtime(data_runtime)
104
```

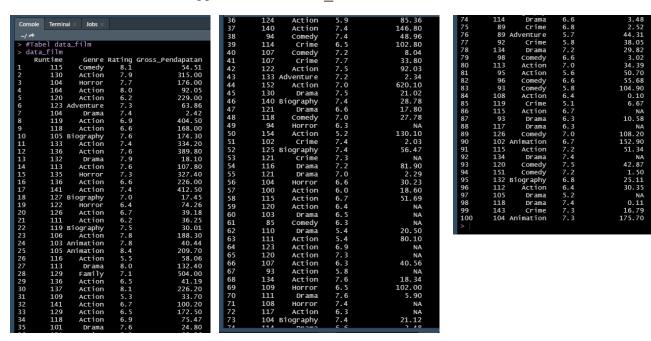
/UB34 -ating <-function(data_rating){ _rating <-unique(data_rating) _rating <-table(data_rating) (unik_rating)[tabel_rating == max(tabel_rating)]

_rating(data_rating)

Output Hasil

Data Frame Film

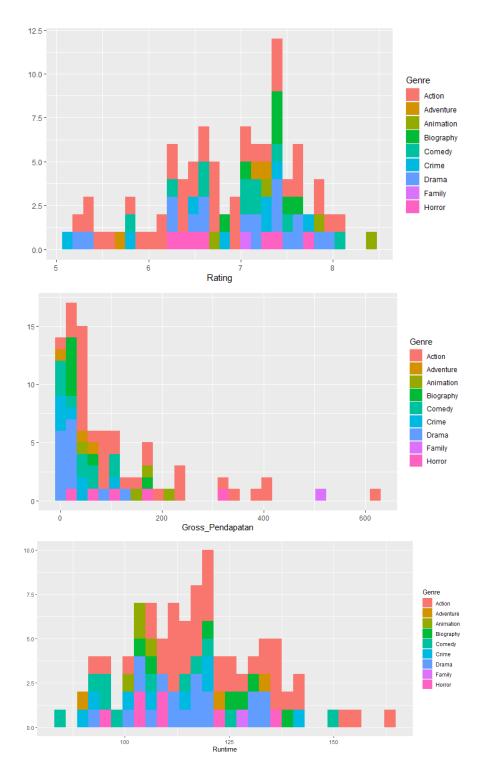
Karena sebelumnya data film sudah dibuat data frame maka perintah untuk melihat data frame film menggunakan > data_film



• Histogram Data Film

Perintah dalam R untuk membuat histogram data film yaitu

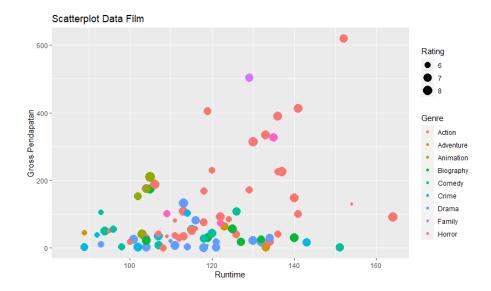
```
> library("ggplot2")
> qplot(data = data_film, Rating, fill = Genre, bins = 30)
> qplot(data = data_film, Gross_Pendapatan, fill =
Genre, bins = 30)
> qplot(data = data_film, Runtime, fill = Genre, bins = 30)
Kemudian akan diperoleh hasil output sebagai berikut
```



• Scatterplot Data Film

Perintah dalam R untuk membuat scatterplot data film yaitu

Kemudian akan diperoleh hasil output sebagai berikut



> Analisis Data

• Statistik Deskriptif

Berdasarkan hasil analisis statistik deskriptif menggunakan R diperoleh :

- 1. Nilai terkecil atau minimum dari data Runtime, Rating, dan Gross_Pendapatan masing-masing adalah 85.0, 5.100, dan 0.10.
- 2. Nilai terbesar atau maksimum dari data Runtime, Rating, dan Gross_Pendapatan masing-masing adalah 164.0, 8.400, dan 620.10.
- 3. Kuartil bawah (1st Qu.) dari data Runtime, Rating, dan Gross_Pendapatan masingmasing adalah 105.0, 6.400, dan 21.05.
- 4. Median dari data Runtime, Rating, dan Gross_Pendapatan masing-masing adalah 116.5, 7.000, dan 49.83.
- 5. Rata-rata atau mean dari data Runtime, Rating, dan Gross_Pendapatan masing-masing adalah 117.1, 6.879, dan 97.51.
- 6. Kuartil atas (3st Qu.) dari data Runtime, Rating, dan Gross_Pendapatan masingmasing adalah 127.5, 7.400, 124.62.
- 7. Varian dari data Runtime dan Rating masing-masing adalah 248.8137 dan 0.5432919, sedangkan untuk data Gross_Pendapatan bernilai NA karena terdapat beberapa data yang tidak ada nilainya.
- 8. Standar deviasi dari data Runtime dan Rating masing-masing adalah 15.77383 dan 0.7370834, sedangkan untuk data Gross_Pendapatan bernilai NA karena terdapat beberapa data yang tidak ada nilainya.
- 9. Modus dari data Runtime dan Rating masing-masing adalah 104 dan 7.4, sedangkan untuk data Gross_Pendapatan tidak mempunyai modus karena semua data hanya muncul 1 kali.
- 10. Data Genre tidak mempunyai nilai terkecil, nilai terbesar, kuartil bawah, kuartil atas, median, mean, varian, dan standar deviasi karena data Genre termasuk data kulitatif. Tetapi data Genre mampunyai modus yaitu Action sehingga genre film yang banyak disukai pada tahun 2017 adalah Action.

• Histogram

Berdasarkan hasil output histogram dapat diketahui bahwa 100 film teratas berdasarkan popularitas pada tahun 2017 dengan genre Animation mempunyai rating paling tinggi sedangkan film dengan genre Crime mempunyai rating paling rendah. Film dengan genre Action juga mempunyai gross pendapatan paling tinggi dibandingkan genre lainnya. Dan rata-rata runtime film pada tahun 2017 berada diantara 100 sampai 150 menit tetapi terdapat beberapa film yang mempunyai runtime lebih dari 150 menit yaitu film dengan genre Comedy dan Action.

Scatterplot

Berdasarkan hasil output scatterplot dapat diketahui bahwa 100 film teratas berdasarkan popularitas pada tahun 2017 mempunyai gross pendapatan film paling tinggi yaitu diatas 600 dengan genre film yaitu Action. Kemudian diurutan kedua adalah film dengan genre Family yaitu sekitar 500 dan rata-rata gross pendapatan film pada tahun 2017 adalah antara 0 sampai 200.